

# Aplicación de técnicas de Aprendizaje Automático

Esther Lydia Silva Ramírez  
esther.silva@uca.es

A partir de la archiconocida base de datos *titanic*, cuyos datos reales se encuentran en los ficheros *dataset.csv* y *newData.csv*, y que corresponden a las características de los pasajeros del Titanic, se va a llevar a cabo el análisis de dicho conjunto de datos así como la predicción de la variable explicada. Este conjunto de datos es un clásico poco original, pero resulta muy útil para usarlo como ejemplo en la introducción al aprendizaje automático, al contener características fácilmente comprensibles (edad, género, situación socio-económica,...), de ambos tipos (cualitativas y cuantitativas), suficientes registros para entrenar el modelo predictivo, datos incompletos, etc. Todo ello lo hace idóneo para su uso cuando un aprendiz se introduce en el mundo de las técnicas de *machine learning*.

Para mayor información sobre el conjunto de datos consúltese *Report on the Loss of the 'Titanic' (S.S.) (1990), British Board of Trade Inquiry Report\_(reprint), Gloucester, UK: Allan Sutton Publishing*.

La variable explicada o dependiente indica si la persona sobrevivió o no al hundimiento del Titanic. El objetivo es encontrar alguna relación entre los atributos (variables independientes) y la probabilidad de que un pasajero sobreviva o no al naufragio. Por ejemplo, supervivencia por edad, sexo, clase, etc.

Ambos subconjuntos (*dataset* y *newData*) se encuentran disponibles en la carpeta *Conjunto de datos*, en el campus virtual, y han sido extraídos de *Kaggle*. En el conjunto *dataset.csv* se dispone de toda la información, mientras en el conjunto *newData* se desconoce si el pasajero sobrevivió o no al hundimiento, intentado reflejar así lo que ocurre en la realidad laboral, cuando se trabaja como analista en una empresa. Es decir, son datos que el modelo verá una vez que está desplegado y en funcionamiento, haciendo predicciones para escenarios donde la variable objetivo aún no ha ocurrido o no ha sido observada.

## Exploración de los datos

Realizar una representación gráfica de las variables y un estudio estadístico de las mismas.

- Implementar el código necesario para realizar un análisis descriptivo de los datos: medidas de frecuencia, tendencia, dispersión, posición, distribución.
- Comprobar que no haya variables que tengan valores constantes (su valor es el mismo para todos los registros), ya que estas variables añaden al modelo más ruido que información, por lo que suele ser conveniente eliminarlas.
- A partir de este análisis exploratorio se pueden excluir aquellas variables que no aporten nada al estudio, acorde al criterio del experto (analista).

## Preprocesamiento

Como ya se ha estudiado, el preprocesamiento de los datos engloba un conjunto de técnicas de análisis de datos que permiten mejorar la calidad de los mismos, dando lugar a un conjunto preparado para aplicar técnicas de extracción de conocimiento (minería de datos) obteniendo más información y de mayor calidad.

## Depuración de datos

### Fase I - Detección de outliers mediante técnicas estadísticas:

- Implementar el código necesario para aplicar técnicas estadísticas en la detección de valores sospechosos de ser outliers: método basado en la desviación típica, rango intercuartílico y diagrama de caja.  
Recordemos que la altura de la caja es el rango intercuartílico. Y el «bigote» (la línea gruesa) es la mediana. Las líneas inferior y superior son los límites que marcan el umbral para los valores atípicos.
- Estudiar la media, mediana y cuartiles para comprobar si los outliers tienen mucho peso y distorsionan los datos.
- Hay que determinar bien dónde se producen los valores atípicos.
- Una opción para solucionar este problema de los outliers es prescindir de los registros que los contengan.
  - Generar la BD resultante de eliminar los registros que contengan esos valores atípicos detectados.
  - Volver a estudiar la caja de bigotes, media, mediana y cuartiles.
  - Comparar los resultados antes y después del proceso de eliminación. ¿Han cambiado los valores?
- Otra opción es, una vez detectados los valores atípicos, marcarlos como datos perdidos para proceder a su reemplazo en la siguiente fase.

### Fase II - Tratamiento de valores perdidos - eliminación:

- Generar la BD resultante de eliminar los registros o las variables que contengan datos perdidos. ¿Qué ha ocurrido?
- Volver a ejecutar las técnicas estadísticas.
- Comparar los resultados antes y después del proceso de eliminación.

Si el porcentaje de registros con datos perdidos no es muy alto y se cuenta con muchas observaciones, se podría aplicar esta opción, pero hay que tener en cuenta que implica pérdida de información.

### Fase III - Tratamiento de valores perdidos - imputación:

- A partir de la BD con datos incompletos.
  - Imputar estos valores incompletos con la media de los valores observados, almacenando la BD resultante del proceso de imputación.
  - Volver a realizar el análisis estadístico.
  - Comparar los resultados con los obtenidos en los pasos anteriores.

El método de interpolación más simple es localizar el valor del registro más cercano y asignar al dato perdido el mismo valor que tenga ese registro en ese atributo.

- Imputar los valores incompletos con el valor del vecino más cercano (clase *interpolate* de Python) de los valores observados, almacenando la BD resultante del proceso de imputación.
- Volver a realizar el análisis estadístico.
- Comparar los resultados con los obtenidos en los pasos anteriores.

## Transformación de los datos

En esta fase hay que llevar a cabo las transformaciones de los atributos, si fuera necesario.

Recordemos que cuando las variables son **numéricas** es importante tener en cuenta la escala en la que se miden, ya que puede influir en gran medida en el entrenamiento del modelo. Para el escalado de los datos se puede llevar a cabo:

- Normalización

Los datos pueden ser normalizados, es decir, se puede transformar el rango de valores a un intervalo determinado.

Es una forma simple de escalar valores en una columna. Es el resultado de la resta del valor menos el valor mínimo entre la diferencia entre el valor máximo y el mínimo de la columna:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Analizar si alguna de las variables necesita este tipo de transformación.

- Estandarización

Los datos pueden ser estandarizados, es decir, transformar los valores de los atributos para que tengan media 0 y desviación 1. Sólo si la distribución es normal.

$$X_{estd} = \frac{X - \mu}{\sigma}$$

Analizar si alguna de las variables necesita este tipo de transformación.

En el análisis exploratorio habrá observado los valores de la variable *fare*. ¿Qué le ocurre a esta variable? ¿Qué solución podría darle?

De igual manera, los algoritmos de aprendizaje automático no pueden funcionar directamente con las etiquetas de las variables **categóricas**. Requieren que las variables categóricas se conviertan en variables cuantitativas.

- Podríamos usar una codificación entera directamente, pero esto solo es posible para variables ordinales donde existe una relación ordinal natural entre las categorías.
- Cuando no hay una relación ordinal, permitir que la representación se apoye en dicha relación puede complicar la resolución del problema. En estos casos se define una variable binaria para cada categoría, la variable que corresponde a la categoría se establece en 1 y el resto de variables en 0.

Realice las transformaciones que considere oportunas a los predictores.

## Reducción del conjunto

En este punto se podría realizar una selección de características. Existen muchas técnicas para llevar a cabo esta selección. Desde técnicas estadísticas hasta técnicas más complejas usando herramientas de aprendizaje automático. Algunas de las técnicas estadísticas podrían ser, por ejemplo: correlación de Pearson, percentiles, eliminación usando la varianza más baja (VarianceThreshold), selección univariable (SelectKBest), eliminación de características recursivas, etc.

Igualmente, si fuera necesario, también podría llevarse a cabo la selección de instancias. Dado que para este conjunto se ha realizado eliminación de datos, al tratarse de una base de datos pequeña, se podría obviar este paso.

## Generación de modelos

Una vez realizado el preprocesamiento anterior al conjunto de entrenamiento y conjunto test se procede a generar los modelos. Se deberán aplicar todos los modelos estudiados tanto de aprendizaje no supervisado como aprendizaje supervisado.

### Asociación - Algoritmo A Priori

- Conjuntos de ítems y reglas obtenidas.
- Código que generaliza el uso del algoritmo Apriori para diferentes valores de los parámetros.
- Conclusiones obtenidas.

### Clustering - Algoritmo k-means

- Calcular el número de clusters y valor de la semilla que considere óptimos aplicando el método de k-means. Justifique su elección.
- Aplicar el algoritmo de clustering con los parámetros obtenidos en el paso anterior.
- Extraer conclusiones a partir del modelo obtenido.

## Clasificación

Genere los subconjuntos necesarios aplicando algún método de validación: Random-hold-out, k-fold cross-validation, Bootstrap,...

Para el entrenamiento de los modelos se pueden usar los valores por defecto de los hiperparámetros o bien emplear búsqueda *GridSearchCV*. Como ya se estudió, esta última es una buena solución disponible en *scikit-learn* que permite hacer una búsqueda de los valores de los hiperparámetros en los modelos de *Machine Learning*.

### Clasificador Bayesiano Ingenuo

- Genere el código necesario para aplicar el Clasificador Bayesiano Ingenuo a los pares de conjuntos obtenidos anteriormente con la técnica de validación.
- Genere el código necesario para obtener el error cometido al clasificar.

### Clasificador Árboles de decisión

- Genere el código necesario para aplicar el algoritmo C4.5 a los pares de conjuntos obtenidos anteriormente con la técnica de validación.
- Ejecute el algoritmo sobre distintos valores de los hiperparámetros.
- Genere el código necesario para obtener el error cometido al clasificar para cada experimento del paso anterior.
- ¿Qué valores de los parámetros conducen a un buen resultado?

## Clasificador k-NN

- Implemente el código necesario para ejecutar el algoritmo  $k$ -vecinos más cercanos a los pares de conjuntos obtenidos anteriormente con la técnica de validación.
- Aplique alguna técnica para seleccionar el mejor valor de  $k$ .
- Genere el código necesario para obtener el error cometido al clasificar.

## Clasificador Perceptrón Multicapa

- Implemente el código necesario para ejecutar el Perceptrón Multicapa a los pares de conjuntos obtenidos anteriormente con la técnica de validación.
- Intente optimizar los valores de los hiperparámetros como el número de neuronas en la capa oculta o el número de épocas.
- Genere el código necesario para obtener el error cometido al clasificar.

## Clasificador Autoencoder

- Implemente el código necesario para ejecutar Autoencoder a los pares de conjuntos obtenidos anteriormente con la técnica de validación.
- Intente optimizar los valores de los hiperparámetros.
- Genere el código necesario para obtener el error cometido al clasificar.

## Aplicación de los modelos en entorno de simulación real

Una vez que haya obtenido el mejor modelo de Machine Learning para cada algoritmo de los estudiados, basándose en las métricas obtenidas durante la fase de validación con el conjunto de test, deben proceder a su despliegue final simulado. Este proceso consta de dos pasos que replican las mejores prácticas en la industria:

1. Reentrenamiento con datos históricos completos. Antes de *ponerlo en producción*, el modelo ganador en cada algoritmo debe ser reentrenado utilizando la totalidad de los datos históricos disponibles, es decir, la unión de los conjuntos de entrenamiento y test originales. Esto maximiza el aprendizaje del modelo, ya que aprovecha toda la información conocida. El modelo final resultante de este reentrenamiento es el que se utiliza para la predicción.
2. Predicción sobre el conjunto de datos desconocido (simulación de producción). El modelo final de cada algoritmo, maximizado con todos los datos históricos, deberá aplicarse al conjunto de datos completamente nuevo (*newData*) y no visto durante el entrenamiento (simulando los datos que llegan en tiempo real al sistema).

NOTA.- Bajo ninguna circunstancia se debe volver a ajustar o reentrenar el modelo con estos datos nuevos.

## Documentación a entregar

Se deberá hacer entrega de un cuaderno de Jupyter Notebook que contenga tanto el código como toda la explicación detallada y razonada de cada fase realizada incluyendo la aplicación de todos los clasificadores estudiados al conjunto test. Así como las conclusiones que se pueden extraer de este estudio.

El uso de cualquier otra técnica adicional a las anteriores se valorará muy positivamente.

En el cuaderno *ABD\_ApellidosNombre* se deben incluir:

- Resultados que incluyan gráficas, análisis, métricas de la calidad de los modelos, etc.
- Tablas comparativas de resultados.
- Conclusiones obtenidas después del análisis de resultados.
- Todo el código generado en todos los pasos: análisis exploratorio, depuración, aplicación de los modelos, etc.